FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Kostka, A., Chudziak, J.A. (2026). Evaluating Theory of Mind and Internal Beliefs in LLM-Based Multi-agent Systems. In: Nguyen, N.T., et al. Computational Collective Intelligence. ICCCI 2025. Lecture Notes in Computer Science(), vol 16138. *Springer, Cham*. DOI: 10.1007/978-3-032-09318-9_2	D-03	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original (propuesta metodológica e investigación experimental)	Springer — *Chinese Journal of Aeronautics*	Scopus

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Presentar un sistema multiagente con Teoría de la Mente (ToM), creencias internas y solucionadores simbólicos para potenciar la inteligencia colaborativa en sistemas multiagentes (MAS), evaluando su rendimiento bajo distintas configuraciones de LLM.
Problema / Brecha	Las LLM son habilidosas a la hora de procesar lenguaje natural, pero su razonamiento es propenso a errores y puede ser inconsistente lógicamente, además de presentar desafíos en ambientes multiagentes como a la hora de adaptarse en configuraciones dinámicas e inciertas, manejo de memoria y coordinación con otros agentes. De manera similar, la integración sinérgica de la ToM, creencias internas basadas en BDI y solucionadores simbólicos sigue sin explorarse.
Metodología	Los autores comienzan describiendo el ambiente de la tarea, luego la arquitectura de agente y finalizan con la integración de herramientas lógicas para la verificación. Durante la implementación, prueban distintas configuraciones para contrastarlas, para luego presentar un resumen experimental y los resultados numéricos en forma gráfica y tabular, además de proveer un análisis de la interacción entre los agentes y el rendimiento del sistema.
Población / Ámbito	El estudio se sitúa en el área de sistemas multi-agente basados en LLMs ,evaluando una población compuesta por los modelos ChatGPT-4o, ChatGPT-3.5-Turbo, Llama 3.1 8B y Claude 3.5 Sonnet. El dominio de aplicación es un entorno virtual de asignación de recursos urbanos donde los agentes coordinan suministros de comida, medicina y seguridad. .

Campo	Información Extraída
Intervención / Propuesta	El entorno de la tarea es un problema de distribución dinámica de recursos, donde los agentes deben coordinarse para mantener la salud de vecindarios urbanos. 1. La ciudad tiene 4 distritos, donde d1 es el nodo de reabastecimiento. La salud de cada distrito comienza en 100 puntos y va decreciendo por cada turno. 2. Cada agente es asignado para proveer comida, medicina o seguridad. Sus acciones se limitan a moverse a un distrito adyacente o suplir recursos al distrito actual. 3. Los agentes tienen 4 módulos: creencias sobre otros, creencias internas, acciones y respuestas. Los dos primeros módulos interactúan dinámicamente, y pueden ser apagados dependiendo del experimento. 4. El módulo de creencias internas es procesado mediante una herramienta lógica de Answer Set Programming (ASP), logrando detectar inconsistencias y permitiendo al agente corregir sus creencias de ser necesario, antes de que estas influyan en las acciones. 5. Al comienzo de cada turno, se informa a los agentes de la salud, recursos disponibles y su inventario. En cada turno los niveles de recursos son reevaluados. 6. La salud promedio de los distritos d2, d3 y d4 sirve como métrica principal para evaluar el rendimiento del sistema.
Resultados Principales	El impacto de ToM fue inconsistente, ya que los modelos menos avanzados hacían predicciones falsas que causaban descoordinación. Similarmente, el módulo de creencias internas (IB) ocasionó que los modelos más refinados tuviesen creencias consistentes más exitosamente. Los modelos más destacados fueron ChatGPT-4o y Claude 3.5 Sonnet, probablemente por su capacidad de integrar ToM e IB sin pérdidas de rendimiento. En otros modelos con razonamiento más restringido, no siempre mejoraba el rendimiento, causando a veces confusión sobre las intenciones de otros y generando creencias internas inconsistentes.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Se emplea una estructura de comunicación secuencial apoyada en un sistema de memoria dual. Los agentes intercambian información, planes y observaciones a través de una memoria compartida que actúa como base de conocimiento colectivo. Paralelamente, emplean una memoria privada para aislar su razonamiento interno y deliberar de forma individual.
Métricas reportadas	1. Puntuación mediana de salud final de los distritos: Es la métrica principal para evaluar el rendimiento del sistema. Representa la salud promedio de todos los distritos (excluyendo el nodo de suministro) al terminar la simulación. 2. Niveles de recursos: Miden la cantidad de recursos (comida, medicina y seguridad) disponibles en cada distrito turno a turno. 3. Intervalos de confianza del 95 %: Calculados mediante la técnica de bootstrapping, se utilizan para medir la variabilidad y la confiabilidad de las puntuaciones de salud obtenidas por los diferentes modelos de lenguaje bajo diversas configuraciones.
Tipos de fallo colectivo considerados	El estudio analiza fallos colectivos como la falta de coordinación y las decisiones subóptimas, derivadas de predicciones erróneas o suposiciones falsas sobre las intenciones de otros agentes al aplicar la Teoría de la Mente. También advierte sobre la generación de creencias internas inconsistentes y sobrecargas cognitivas que provocan confusión, problemas que se ven agravados por las ineficiencias inherentes al protocolo de comunicación secuencia.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El paper es relevante a la hora de demostrar una vez más la importancia de escoger bien un modelo, y que no todas las nuevas características son beneficiosas para todos los agentes LLM.
Limitaciones / Sesgos	La principal limitación metodológica es la simplicidad del entorno de tareas, lo cual restringe la generalización de los hallazgos. Además, existen aspectos no resueltos de escalabilidad debido al alto costo computacional del solucionador lógico y al sobreesfuerzo cognitivo que estos mecanismos exigen.
Conclusión del Autor	La inclusión de mecanismos ToM e IB no son una característica universal de mejora para todos los LLM: en agentes con menos capacidad nativa de razonamiento, experimentaron poca mejora o incluso efectos adversos. Concluyen que se debe prestar atención particular a la selección del modelo, la complejidad de la tarea y la construcción del mecanismo de interacción.
Impresión del Estudiante	⋆ ⋆ ⋆⋆ **(Bueno).** El paper es bueno, ya que presenta un framework que propone una forma de visualizar los pensamientos internos de un agente y corregirlos antes de que actúen. Relacionado con el tema.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.