FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Yan, B., Zhou, Z., Zhang, X., Li, C., Zeng, R., Qi, Y., Wang, T., & Zhang, L. (2026). .Attack the Messages, Not the Agents: A Multi-round Adaptive Stealthy Tampering Framework for LLM-MAS". *Proceedings of the Fortieth AAAI Conference on Artificial Intelligence and Thirty-Eighth Conference on Innovative Applications of Artificial Intelligence and Sixteenth Symposium on Educational Advances in Artificial Intelligence*. DOI: 10.1609/aaai.v40i35.4022	D-06	2026

Tipo de Estudio	Base de Datos	Indexación
Artículo de conferencia / estudio experimental con propuesta metodológica.	AAAI Proceedings / AAAI OJS.	Scopus

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	El objetivo principal del estudio es diseñar y proponer un nuevo marco de ataque llamado MAST (Multi-round Adaptive Stealthy Tampering), destinado a explotar las vulnerabilidades de comunicación dentro de los Sistemas Multiagente basados en Grandes Modelos de Lenguaje (LLM-MAS).
Problema / Brecha	Los autores identifican que los métodos de ataque actuales contra los LLM-MAS enfrentan un obstáculo insuperable: no logran ser simultáneamente efectivos, adaptables y sigilosos. Los ataques existentes suelen intentar comprometer directamente a los agentes (mediante inyecciones de prompts o jailbreaks) o interceptar mensajes usando técnicas de persuasión muy evidentes y basadas en plantillas manuales predefinidas.
Metodología	El estudio utiliza una metodología empírica cuantitativa y algorítmica. Para entrenar su modelo de ataque, integraron la Búsqueda en Árbol de Monte Carlo (MCTS) para explorar secuencias de planificación a largo plazo y la Optimización Directa de Preferencias (DPO) para afinar el modelo de ataque. La evaluación y recopilación de datos se realizó simulando ataques en diferentes arquitecturas de comunicación (plana, en cadena y jerárquica) y comparando el desempeño de MAST contra otros cuatro ataques de referencia (Debate-Attack, AutoInject, AiTM-Target y AiTM-Dos).
Población / Ámbito	El ámbito de aplicación es la ciberseguridad orientada a los ecosistemas de Inteligencia Artificial colaborativa (LLM-MAS).
Intervención / Propuesta	La propuesta central es el marco de trabajo MAST, el cual interviene las comunicaciones de los agentes en dos grandes etapas: el Aprendizaje Adaptativo de Políticas de Ataque y la Manipulación Restringida por Sigilo.
Resultados Principales	Los autores demuestran que el marco MAST supera a los ataques existentes, logrando simultáneamente altas Tasas de Éxito de Ataque y un excelente nivel de sigilo. Evaluado en múltiples arquitecturas y tareas, la evidencia confirma que sus restricciones duales evitan eficazmente la detección. Además, las comparaciones revelan que los modelos de código abierto ajustados con este método superan en rendimiento a sistemas como GPT-4o y Gemini.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	El estudio modela la comunicación como un grafo dirigido donde los agentes intercambian mensajes a través de enlaces específicos. Específicamente, reporta y evalúa tres arquitecturas de comunicación diferentes: plana (flat, donde discuten por igual), secuencial (chain) y jerárquica.
Métricas reportadas	1. Tasa de Éxito del Ataque (ASR): Evalúa la efectividad general de la intervención (se considera que un ataque es exitoso si el objetivo del atacante se refleja claramente en la salida o resultado final del sistema). 2. Sigilo: Mide la capacidad del ataque para pasar desapercibido y evadir la detección, utilizando para ello un agente defensor encargado de revisar todos los mensajes de comunicación en tránsito.
Tipos de fallo colectivo considerados	El paper analiza fallos inducidos por vulnerabilidades compartidas en la comunicación, destacando la desviación de objetivos, consensos incorrectos, denegación de servicio y propagación de información maliciosa. Estos colapsos ocurren debido a la susceptibilidad del sistema a la intercepción y manipulación encubierta de los mensajes intercambiados por los agentes.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	Es buen aporte ponerse del lado del atacante en modelos MAS-LLM, no es común y por tanto se toma como punto a favor.
Limitaciones / Sesgos	El estudio parte de la fuerte suposición de que el atacante ya tiene la capacidad previa de interceptar y controlar parcialmente los enlaces de comunicación del sistema, operando como un intermediario (ataque MITM). Además, el éxito del ataque depende en gran medida del ajuste manual de los umbrales de similitud semántica y de incrustación (embedding), los cuales, si son demasiado estrictos, reducen drásticamente la capacidad de manipulación del atacante.
Conclusión del Autor	Los autores concluyen que su marco de trabajo (MAST) es altamente efectivo para vulnerar sistemas multiagente, logrando alterar el resultado de las tareas con un gran éxito y sin ser detectado. A diferencia de los ataques tradicionales que intentan romper directamente las barreras de seguridad del modelo, MAST demuestra que planificar pequeños sabotajes a lo largo de múltiples rondas de comunicación y disfrazarlos con reescrituras sutiles permite eludir los mecanismos de defensa actuales.
Impresión del Estudiante	⋆⋆ **(Regular).** El paper presenta una visión alarmante sobre el futuro de la IA: un atacante no necesita hackear el cerebro del agente, sino que le basta con introducir reescrituras sutiles para desviar por completo su objetivo.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.