FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Darwish, Ahmed M., Essam A. Rashed, and Ghada Khoriba. (2025). Mitigating LLM Hallucinations Using a Multi-Agent Framework. *Information 16, no. 7: 517.* DOI: 10.3390/info16070517	D-15	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original con propuesta metodológica y estudio experimental.	mdpi	Scopus y Web of Science

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	El objetivo de los autores es proponer un framework híbrido multiagente que integra la generación de los LLMs con un sistema de validación basado en reglas lógicas, para mitigar las alucinaciones y garantizar respuestas consistentes y confiables en aplicaciones de producción a gran escala.
Problema / Brecha	Inconsistencia y las alucinaciones de los LLMs que impiden su despliegue confiable en entornos de producción a gran escala. Para ello, cubre la brecha de los sistemas multiagente actuales, los cuales carecen de controles estructurados y escalabilidad para garantizar validaciones factuales predecibles.
Metodología	Experimentalmente, el sistema fue probado utilizando un conjunto de datos de 308 transcripciones reales de un centro de llamadas del sector automotriz, las cuales fueron procesadas previamente con herramientas de conversión de voz a texto y diarización de locutores. La arquitectura implementa al modelo LLaMA-3-8B como un agente consultor encargado de reestructurar los diálogos, y al modelo Mistral-7B como un agente evaluador que utiliza capacidades de ejecución de código para aplicar el algoritmo de coincidencia de patrones de Ratcliff y Obershelp. Esta técnica calcula una puntuación de similitud entre la respuesta generada y el texto original: si el puntaje cae por debajo del 80 %, el sistema asume que hubo una alucinación (como un cambio de hablante o un parafraseo no deseado) y activa un bucle de retroalimentación. Este ciclo controlado exige al consultor que corrija sus propios errores durante un máximo de dos iteraciones, evaluándose finalmente la eficacia del modelo mediante métricas estadísticas que cuantifican la reducción de la tasa de alucinaciones a lo largo del proceso.
Población / Ámbito	Área de la Inteligencia Artificial y los sistemas multiagente, aplicándose al dominio del procesamiento de lenguaje natural para validar transcripciones reales de servicio al cliente de un centro de llamadas comercial del sector automotriz.

Campo	Información Extraída
Intervención / Propuesta	El artículo propone un marco de trabajo híbrido multiagente diseñado para mitigar las alucinaciones de LLMs y garantizar respuestas consistentes en entornos de producción: 1. El agente consultor utiliza un modelo LLM (como LLaMA-3-8B) encargado de ejecutar la tarea principal, como por ejemplo limpiar y estructurar transcripciones de diálogos sin reescribir el contenido original ni confundir a los hablantes. 2. El agente evaluador emplea otro modelo (como Mistral-7B) configurado como un invocador de funciones con capacidad de ejecutar código, diseñado exclusivamente para auditar objetivamente el desempeño del consultor. 3. El sistema aplica el algoritmo de coincidencia de patrones de Ratcliff y Obershelp para calcular una puntuación matemática de similitud entre el fragmento de texto original y la respuesta generada por el consultor. 4. Si la puntuación de similitud de un fragmento cae por debajo de un umbral estricto (80 %), se considera una alucinación; el evaluador marca el error y exige al consultor que corrija su respuesta en un ciclo que finaliza cuando ya no hay errores o tras un máximo de dos iteraciones. 5. Un agente administrador divide el proceso general en interacciones más pequeñas y controlables, delegando el trabajo a los agentes subordinados para evitar que la conversación divague o pierda su propósito. 6. Todo el comportamiento de ejecución y las puntuaciones de cada agente se registran en una base de datos centralizada, facilitando el monitoreo continuo, el diagnóstico de anomalías y la optimización del sistema.
Resultados Principales	Los autores reportaron que el marco redujo las alucinaciones en un 85.5 % para LLaMA-3-8B y un 67.7 % para Mistral-7B tras dos iteraciones de corrección. Comparativamente, LLaMA-3-8B demostró una mayor eficacia y consistencia que Mistral-7B para generar respuestas precisas y estructuradas.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Estructura de comunicación jerárquica y secuencial organizada en chats anidados y orquestada centralmente por un agente líder. Este agente principal divide el flujo de trabajo y delega tareas a pares de agentes subordinados (un consultor y un evaluador) que interactúan directamente mediante un bucle de retroalimentación iterativo y controlado.
Métricas reportadas	1. Puntuación de similitud: Es la métrica principal del estudio. Se calcula utilizando el algoritmo de coincidencia de patrones de Gestalt (específicamente Ratcliff y Obershelp) para obtener una medida matemática de qué tanto coincide la respuesta generada por el agente con el fragmento de texto de referencia original. 2. Tasa de alucinaciones: Representa el porcentaje de fragmentos generados cuya puntuación de similitud cae por debajo de un umbral predefinido del 80 %. Cualquier resultado por debajo de este nivel es marcado como una alucinación. 3. Estadísticas descriptivas de consistencia: Para capturar no solo la calidad promedio sino también la distribución y variabilidad de las respuestas, los autores calcularon la puntuación de similitud media, la desviación estándar, los valores mínimos y máximos, así como los percentiles 25, 50 (mediana) y 75 a lo largo de las distintas iteraciones. 4. Intervalos de confianza del 95 %: Se calcularon alrededor de las tasas de alucinaciones para cuantificar la incertidumbre y proporcionar un rango estadístico robusto donde se espera que se encuentre la tasa real de alucinaciones. 5. Métricas de seguimiento de iteraciones y errores: Los autores contabilizaron el número exacto de fragmentos alucinados frente al número de fragmentos corregidos con éxito tras la primera y segunda iteración del bucle de retroalimentación, calculando así el porcentaje total de reducción de alucinaciones del sistema. 6. Eficiencia de procesamiento: Aunque no es la métrica principal de calidad, evaluaron la viabilidad operativa reportando el tiempo total de ejecución computacional.
Tipos de fallo colectivo considerados	El estudio señala como principales fallos colectivos en los sistemas multiagente la tendencia a exhibir comportamientos divergentes, deriva semántica y discusiones fuera de tema, originados por la falta de control en las transiciones entre los agentes.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	Es un aporte relevante para sistemas LLM-MAS, además de contar con evaluaciones robustas.
Limitaciones / Sesgos	Las principales limitaciones radican en el uso exclusivo de diálogos en inglés provenientes de un único dominio comercial, lo que introduce posibles sesgos demográficos y estructurales que restringen la generalización del modelo a otros idiomas o sectores.
Conclusión del Autor	Los autores concluyen que su marco híbrido multiagente reduce significativamente las alucinaciones y mejora la consistencia factual de los LLMs en entornos de producción. Esta solución práctica y estructurada facilita el despliegue confiable de estos modelos a gran escala para resolver problemas del mundo real.
Impresión del Estudiante	⋆ ⋆ ⋆⋆ **(Bueno).** Es un framework completo, falta evaluar la pertinencia a las preguntas de investigación de mi estudio.

5. OBSERVACIONES GENERALES Y NOTAS

N **Nota**

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.