FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Hu, J., Dong, Y., Ding, Z., & Huang, X. (2025). Enhancing robustness of LLM-driven multi-agent systems through randomized smoothing. *Chinese Journal of Aeronautics*. DOI: 10.1016/j.cja.2025.103779	V-01	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original: simulación y propuesta de marco de defensa.	ScienceDirect (Elsevier) — *Chinese Journal of Aeronautics*	Scopus / Web of Science (WoS)

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Presentar un marco de defensa basado en suavizado aleatorio (*randomized smoothing*) para mejorar la seguridad y robustez de los sistemas multi-agente (MAS) impulsados por LLMs en dominios críticos, proporcionando garantías probabilísticas durante la toma de decisiones de los agentes bajo influencia adversaria.
Problema / Brecha	La integración de LLMs en sistemas autónomos introduce riesgos específicos, como alucinaciones que pueden propagarse por la red y vulnerabilidades ante perturbaciones adversarias capaces de alterar el comportamiento de los agentes. Los métodos tradicionales de verificación formal suelen exigir modelos matemáticos precisos o transparencia de "caja blanca", condiciones poco compatibles con la naturaleza estocástica y de "caja negra" de los LLMs. Por ello, faltan mecanismos que otorguen garantías formales de seguridad para el consenso en MAS basados en LLMs.
Metodología	Los autores adaptaron matemáticamente la técnica de certificación por *randomized smoothing* hacia espacios de estado continuo en MAS. Evaluaron el método empíricamente mediante consultas al modelo GPT-3.5-Turbo, simulando un MAS con estructura de anillo compuesto por 10 agentes y un entorno aeroespacial tridimensional con drones/UAVs, donde los agentes debían alcanzar consenso de vuelo cooperativo pese a la inyección de información maliciosa.
Población / Ámbito	Inteligencia artificial aplicada a sistemas multi-agente en dominios de seguridad crítica, con énfasis en operaciones aeroespaciales, navegación de vehículos aéreos no tripulados (UAV) y sistemas distribuidos en enjambre.
Intervención / Propuesta	Los autores proponen un esquema de **suavizado aleatorio de doble nivel**: 1. En lugar de aceptar directamente los datos de los vecinos, cada agente realiza consultas repetidas e inyecta ruido gaussiano ligero a los *inputs* recibidos para filtrar inconsistencias o manipulaciones. 2. El propio agente aplica muestreo de Monte Carlo a su modelo LLM antes de tomar una decisión. Además, incorporan una **estrategia de muestreo adaptativo**, mediante la cual el agente varía la cantidad de consultas o verificaciones según la varianza detectada en los datos, equilibrando seguridad y costo computacional.
Resultados Principales	El marco propuesto evita que comportamientos adversarios y alucinaciones se propaguen por toda la red de agentes, preservando el consenso y el rendimiento operativo en escenarios simulados. La defensa muestra un efecto de amortiguación local y de red: al proteger cada agente individual, reduce la probabilidad de que perturbaciones aisladas comprometan la formación cooperativa completa.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	El estudio utiliza una topología basada en un grafo dirigido y estructurada en anillo. En esta configuración, el sistema es descentralizado y cada agente se comunica únicamente con sus vecinos adyacentes.
Métricas reportadas	Se emplean métricas de desviación de estado que evalúan la diferencia entre el estado final del agente bajo ataques maliciosos (con y sin defensa) y su estado en un escenario base ideal. Además, se mide el rendimiento promedio de los agentes normales frente a manipulaciones y el porcentaje de mejora de la defensa, calculando la reducción porcentual de la desviación lograda por el mecanismo implementado.
Tipos de fallo colectivo considerados	El estudio analiza principalmente la propagación de desinformación y alucinaciones en la red que comprometen la toma de decisiones, así como la intervención de agentes maliciosos encubiertos (tanto internos como interceptores externos) cuyo fin es perturbar el consenso colectivo evadiendo su detección. También contempla problemas como la propagación de errores en cascada por todo el sistema y la aparición de patrones de coordinación involuntarios (comportamientos emergentes) que desvían al grupo de sus objetivos de seguridad.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El marco de suavizado aleatorio constituye un aporte relevante porque conecta garantías probabilísticas con el despliegue seguro de MAS impulsados por LLMs. Su utilidad es alta en escenarios donde un fallo puede generar costos catastróficos, pues ofrece una ruta práctica y escalable para reducir la propagación de comportamientos adversarios y alucinaciones en redes de agentes autónomos.
Limitaciones / Sesgos	La principal limitación es la sobrecarga computacional: al depender de muestreo repetido para cada toma de decisiones, los requisitos de consultas al LLM aumentan de manera considerable. Aunque los autores mitigan este costo mediante consultas en paralelo y muestreo adaptativo, todavía se requiere validación *hardware-in-the-loop* para despliegues en vuelos reales y sistemas físicos de tiempo real. Los autores declaran no tener conflictos de interés.
Conclusión del Autor	El marco de suavizado aleatorio propuesto previene la propagación de comportamientos adversarios y alucinaciones a través de la red de agentes, garantizando el consenso y el rendimiento operativo. En dominios donde el fallo puede tener consecuencias catastróficas, esta aproximación constituye una vía práctica y escalable para desplegar sistemas autónomos basados en IA con garantías formales de seguridad.
Impresión del Estudiante	⋆⋆⋆⋆⋆ **(Excelente).** Propuesta con gran respaldo matemático. Lo más destacado es el uso de una simulación espacial 3D de una flota de drones para demostrar físicamente un problema que suele tratarse de forma puramente algorítmica: sin defensa, la alucinación de un dron podía causar movimientos erráticos y deshacer la formación geométrica en el aire. Es una aproximación indispensable para llevar los LLMs al mundo físico de manera segura.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Visión unificada del riesgo: Un punto particularmente inteligente de la investigación es que trata estadísticamente las *alucinaciones accidentales* del LLM y los *ataques maliciosos intencionados* como un mismo factor: "ruido introducido al sistema". Esto permite usar el mismo mecanismo probabilístico para defenderse de ambas amenazas simultáneamente, sin necesidad de crear filtros separados para cada tipo de perturbación.

Propagación y atenuación en red: Resulta destacable que la aplicación *local* del suavizado en cada agente individual no solo lo protege a él, sino que genera un efecto

de red de “amortiguación de errores” que impide que las perturbaciones adversarias crezcan de forma descontrolada y comprometan todo el ecosistema de agentes en tareas críticas.