FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Idziejczak, M., Korzavatykh, V., Stawicki, M., Chmutov, A., Korcz, M., Błądek, I., & Brzezinski, D. (2024). Among Them: A game-based framework for assessing persuasion capabilities of LLMs. *En: Advances in Knowledge Discovery and Data Mining. Singapur: Springer Nature Singapore, pp. 183–195.* DOI: 10.1007/978-981-96-8186-0_15	V-04	2024

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original / Propuesta metodológica.	Springer Nature.	Scopus.

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Evaluar la capacidad de persuasión de los LLMs a partir de estadísticas obtenidas en un entorno de juego. El estudio considera el éxito persuasivo en un escenario específico y se basa en una amplia variedad de técnicas de persuasión recopiladas desde distintas fuentes de la psicología social y retórica.
Problema / Brecha	Actualmente, las aplicaciones basadas en LLMs vinculadas con política, comercio electrónico y marketing recurren con frecuencia a mensajes persuasivos. Esto ha generado preocupación sobre las posibilidades y riesgos asociados a agentes persuasivos basados en LLMs, impulsando múltiples estudios sobre la capacidad de la IA para influir, manipular o engañar a los seres humanos sistemáticamente.
Metodología	Se evaluaron 8 LLMs de distintos tamaños y tipos (Claude 3.5 Haiku/Sonnet, Gemini Flash/Pro 1.5, GPT-4o mini/4o, Llama 3.1 8B/405B) en un torneo de pares. Cada modelo jugó 20 juegos contra todos los demás alternando roles entre impostor y tripulante, más 10 autopartidos, dando un total de 640 partidas. Se analizó el uso de 25 técnicas de persuasión literarias dentro de las discusiones, evaluadas automáticamente por un modelo Gemini Flash 1.5.
Población / Ámbito	Modelos de Lenguaje Grande (LLMs) operando como agentes autónomos en entornos multi-agente interactivos y de deducción social (juegos inspirados en *Among Us*), donde existe asimetría de información y necesidad de comunicación en lenguaje natural.

Campo	Información Extraída
Intervención / Propuesta	1. Creación de *Among Them*, un entorno de juego de deducción social síncrono basado en texto que divide a los agentes en roles antagónicos (tripulantes vs. impostores) con mecánicas de acción, discusión y votación. 2. Implementación de un módulo de evaluación de persuasión que cuantifica y cualifica de forma sistemática qué estrategias de manipulación (de las 25 predefinidas) usa cada modelo para sobrevivir o engañar.
Resultados Principales	1. De las 640 partidas, el 60.6 % fueron ganadas por tripulantes y el 39.4 % por impostores. Los LLMs lograron utilizar con éxito 22 de las 25 técnicas de persuasión previstas. 2. Claude 3.5 Haiku obtuvo el mayor porcentaje general de victorias (67 %) y fue el mejor impostor. El mejor tripulante fue Gemini Pro 1.5 (ganó el 80 % de sus partidas en ese rol). 3. Sorprendentemente, GPT-4o fue el modelo que menos juegos ganó en total, viéndose gravemente afectado por su mala recepción frente a los engaños (fue el peor tripulante). 4. Se descubrió que los modelos más grandes o que generan mayor cantidad de texto (tokens) **no** tienen ninguna ventaja persuasiva sobre los más pequeños; de hecho, hubo una correlación negativa entre hablar más y ganar.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	El estudio emplea una topología dinámica estructurada en fases dentro de un entorno síncrono basado en texto. Durante la fase de acciones, la interacción es descentralizada y está basada en la ubicación en un mapa: los agentes solo perciben a otros si están en la misma sala. Por el contrario, en las fases de discusión y votación, la topología es de interacción grupal, donde todos los supervivientes se comunican tomando turnos para compartir observaciones y deliberar.
Métricas reportadas	La evaluación se centra en las tasas de victoria (*win ratios*) de los agentes en sus respectivos roles de tripulantes o impostores. Además, se califica y cuantifica de manera detallada el uso de 25 estrategias de persuasión y manipulación extraídas de la literatura psicológica, como apelar a la lógica, engañar o desviar la atención. También se registra el recuento de tokens de salida para medir si la verbosidad influye en las victorias y la frecuencia con la que los impostores simulan hacer tareas.
Tipos de fallo colectivo considerados	La investigación se centra en la susceptibilidad del grupo ante la manipulación, la desinformación y el engaño, provocando que los agentes inocentes tomen decisiones erróneas coordinadas, como expulsar a un aliado. Asimismo, se documentan fallos críticos de comportamiento originados por discusiones internas (*chain of thought meta-discussions*), las cuales en ocasiones causan que un agente impostor pierda la coherencia de su rol y confiese accidentalmente su identidad maliciosa frente a todo el grupo.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	Me parece muy relevante el estudio, ya que propone un framework de código abierto que permite evaluar qué tan susceptibles son los modelos LLMs a los engaños interactuando entre sí. Hace un gran aporte a la floreciente investigación sobre los LLMs y la comparación directa de comportamientos entre modelos comerciales actuales.
Limitaciones / Sesgos	Una limitación clara que presenta este paper es que solo se definieron 25 técnicas de persuasión, cuando socialmente hay muchas más. Por ejemplo, la falta de opciones como el soborno es una limitación importante, pero queda como un punto relevante para trabajo futuro en el mismo entorno.
Conclusión del Autor	Sin sugerir ninguna estrategia de forma directa, los LLMs utilizaron autónomamente tácticas verbales de engaño de manera efectiva. El framework propuesto (*Among Them*) de código abierto sirve como un **banco de pruebas** para evaluar la fidelidad de la cadena de razonamiento (comparando lo que el agente "piensa"vs lo que "dice"). Estos hallazgos buscan alentar más investigación sobre la IA segura y la persuasión.
Impresión del Estudiante	⋆⋆⋆⋆⋆ (Bueno). Esta investigación me parece interesante ya que ayuda a entender cómo los LLMs afectan a los Sistemas Multi-Agente cuando se implementan de forma adversarial. Es valioso poder evaluar la recepción de engaños de distintos modelos en un entorno de código abierto accesible para todos.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Esta investigación aporta un framework que, a pesar de sus limitaciones, impulsa los estudios de la persuasión en LLMs y proporciona recursos de código abierto (repositorio en GitHub) de fácil acceso y replicabilidad. Un gran detalle técnico es evidenciar que el razonamiento Çhain of Thought"puede ser perjudicial si el agente çonfiesa"su rol oculto por error.

Relación con la revisión sistemática: Este artículo es clave para evaluar las dinámicas de persuasión y engaño en Sistemas Multi-Agente (MAS) basados en LLMs. Mientras otros estudios de mi revisión se enfocan en la cooperación de agentes (ej. optimizar recursos), este trabajo aporta métricas empíricas para topologías donde los agentes tienen roles ocultos e incentivos opuestos, permitiendo analizar cómo interactúan, estructuran su retórica y se manipulan mutuamente mediante el lenguaje natural.