# FICHA DE EXTRACCIÓN DE INFORMACIÓN
## (REVISIÓN SISTEMÁTICA)

**Guía Universitaria (UNAP)** | Basado en Mian *et al.* (2005) & PRISMA

---

## 1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

| Referencia | ID Hoja | Año |
|---|---|---|
| Zhang, R., Zhao, X., Wang, R., Chen, S., Zhang, G., Zhang, A., Wang, K., & Wen, Q. (2026). SafeSieve: From Heuristics to Experience in Progressive Pruning for LLM-based Multi-Agent Communication. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(35), 29892–29900. DOI: 10.1609/aaai.v40i35.40236 | V-06 | 2026 |

| Tipo de Estudio | Base de Datos | Indexación |
|---|---|---|
| Artículo de investigación original / propuesta algorítmica y de observabilidad. | AAAI / Web of Science y Scopus (cumple criterios de inclusión) | Conferencia AAAI (indexación de alto impacto compatible con el protocolo) |

## 2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

| Campo | Información Extraída |
|---|---|
| **Objetivo (Intención)** | Proponer *SafeSieve*, un algoritmo que mejora dinámicamente la topología de comunicación en LLM-MAS y mitiga vulnerabilidades mediante la observabilidad del aporte colaborativo. |
| **Problema / Brecha** | Aborda la redundancia en sistemas LLM-MAS y la falta de métodos unificados para auditar qué enlaces aportan valor. Además, soluciona la vulnerabilidad de las largas ventanas de contexto ante ataques de inyección de *prompts*, entendida como una forma de fallo colectivo inducido y un problema subexplorado en métodos de evaluación de caja negra. |
| **Metodología** | Implementación de métricas de proceso mediante matrices de puntuación de enlaces. El estudio realiza pruebas empíricas con LLMs como DeepSeek-V3 y GPT-4o-mini en tareas matemáticas y de programación. También incluye experimentos específicos de inyección de agentes maliciosos para evaluar la detección de fallos sistémicos. |
| **Población / Ámbito** | Sistemas multiagente generativos (LLM-MAS) heterogéneos y homogéneos. |
| **Intervención / Propuesta** | En relación con las preguntas de investigación del protocolo, el sistema propone mecanismos de atribución causal y detección de fallo colectivo.<br>1. **Atribución causal (PI2):** mecanismo de "retroalimentación histórica" ($C_{ij}^{hist}$) que acumula la contribución de cada enlace a las tareas resueltas con éxito y se usa para podar enlaces; los autores no la presentan como atribución causal formal.<br>2. **Detección de fallo colectivo (PI3):** poda progresiva mediante agrupamiento de 0-extensión, que identifica y aísla agentes maliciosos infiltrados sin destruir la coherencia estructural de los agentes sanos. |
| **Resultados Principales** | Permite una alta observabilidad del proceso que decantó en una precisión del 94.01 % con DeepSeek-V3. Su mecanismo de atribución y poda detectó y aisló exitosamente agentes maliciosos en unas 30 rondas, con una caída promedio de precisión de 1,23 % al inyectar agentes de baja calidad, frente a 2,21 % de AgentDropout y 4,59 % de AgentPrune |

## 3. VARIABLES ESPECÍFICAS DE ANÁLISIS

| Pregunta / Variable | Respuesta Extraída |
|---|---|
| **Topología de comunicación empleada** | El estudio emplea una topología de comunicación dinámica basada en un paradigma de pospoda (*post-pruning*). Comienza con una topología densa o completamente conectada que se ajusta de manera progresiva sobre la marcha. Para esto, utiliza un algoritmo llamado SafeSieve, el cual combina evaluaciones semánticas con un mecanismo de agrupación (*clustering*) basado en la extensión-0, lo que permite preservar grupos de agentes estructuralmente coherentes y eliminar los enlaces ineficientes. |
| **Métricas reportadas** | Se evalúa principalmente el desempeño a través de la precisión (*accuracy*) en seis conjuntos de datos de razonamiento general y matemático (MMLU, GSM8K, SVAMP, HumanEval, AQuA y MATH-500). Además, se mide la eficiencia de comunicación calculando la reducción en el consumo de tokens, la robustez del sistema evaluando la caída en la precisión (*accuracy drop*) bajo ataques de inyección de *prompts*, y los costos de despliegue en configuraciones de agentes heterogéneos. |
| **Tipos de fallo colectivo considerados** | La investigación aborda problemas como la comunicación redundante y la excesiva sobrecarga de tokens, las cuales diluyen la atención del sistema sobre la información clave y provocan la degradación de la precisión. También considera la vulnerabilidad del colectivo ante ataques de inyección de *prompts* por la introducción de agentes maliciosos. Por último, busca evitar aislamientos o la eliminación errónea de rutas de comunicación críticas, es decir, la formación de islas de información, un fallo común en los enfoques tradicionales de poda codiciosa (*greedy Top-k*). |

## 4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

| Campo | Valoración del Investigador |
|---|---|
| **Valoración del Investigador** | Extremadamente valioso para la revisión. Aporta un método matemático y computable ($E_{ij}$) para realizar atribución causal directa, evaluando qué interacción específica causó el éxito o fracaso de la tarea. Supera el enfoque tradicional de evaluar MAS solo por el *output* final. |
| **Limitaciones / Sesgos** | En topologías heterogéneas resolviendo tareas de conocimiento, experimenta el "efecto barril", donde el agente más débil limita la inteligencia colectiva del sistema. Esto representa un fenómeno de deriva epistémica incipiente que el algoritmo actual no revierte completamente. |
| **Conclusión del Autor** | SafeSieve valida la eficacia de combinar la inicialización semántica con el refinamiento guiado por la experiencia, demostrando una altísima robustez contra la inyección de agentes maliciosos en la comunicación LLM. |
| **Impresión del Estudiante** | ⋆⋆⋆⋆⋆ **(Excelente).** Es un estudio central para responder la Pregunta de Investigación 2 (PI2: métodos de atribución) y la Pregunta de Investigación 3 (PI3: detección de fallos y engaño sistémico). |

## 5. OBSERVACIONES GENERALES Y NOTAS

𝒩 **Nota**

**Nota principal:** El concepto de "Puntuación Complementaria Histórica" ($C_{ij}^{hist}(t)$) introducido en el paper es la materialización técnica exacta de lo que el protocolo define como "atribución causal del aporte individual". El sistema es capaz de auditar la red y determinar qué nodo introdujo "basura" o engaño sistémico, aislando sus aristas de comunicación.

**Relación con la revisión sistemática:** Cumple estrictamente los criterios de inclusión definidos en la Sección 3.1 del protocolo: vigencia 2021–2026, enfoque en LLM-MAS y datos experimentales sobre el flujo de comunicación. Contribuye directamente a establecer que las métricas de proceso, evaluadas a nivel de *edges* o enlaces, son superiores a las métricas orientadas puramente al *output* para prevenir cascadas de error inducidas por atacantes.