FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Jinxin Shi, Jiabao Zhao, Xingjiao Wu, Ruyi Xu, Yuan-Hao Jiang, Liang He (2025). Mitigating reasoning hallucination through Multi-agent Collaborative Filtering. *Expert Systems with Applications, Volume 263, 125723*. DOI: 10.1016/j.eswa.2024.125723	D-02	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original (propuesta metodológica y estudio experimental).	ScienceDirect (Elsevier)	Scopus y Web of Science

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Proponer MCF (*Multi-agent Collaborative Filtering*), un marco de filtrado colaborativo multiagente basado en el examen cruzado entre agentes, que verifica cada paso del razonamiento y selecciona las respuestas de mayor calidad del espacio de respuestas, con el fin de mitigar las alucinaciones en tareas de razonamiento complejo.
Problema / Brecha	Los sistemas multiagente simples (debate, votación, revisión) no verifican progresivamente cada paso del razonamiento, lo que provoca una acumulación continua de errores. Además, el muestreo aleatorio produce respuestas de calidad inestable sin una estrategia para filtrar las de mayor calidad, y las experiencias de razonamiento exitosas no se aprovechan para mejorar al agente.
Metodología	Un *Task Specifier* detalla la tarea inicial y la entrega a los roles *User* (planificador) y *Assistant* (ejecutor), que dialogan por turnos hasta que el *User* emite la orden `<TASK_DONE>`. Cada rol cuenta con N instancias normales y una instancia adversarial instruida para entregar respuestas incorrectas. En cada paso se calcula la similitud semántica y el grado de coincidencia de grafos AMR (*Abstract Meaning Representation*) entre las respuestas normales y la adversarial, y se filtra la respuesta con mayor probabilidad de ser correcta. Se incorpora un repositorio de experiencias construido automáticamente, con recuperación basada en detección de valores atípicos por Z-score. La evaluación se realizó en diez conjuntos de datos de razonamiento aritmético, de sentido común y simbólico, con los modelos LLAMA2-13B, text-davinci-002, GPT-3.5-Turbo-0613 y GPT-4-0613.
Población / Ámbito	Sistemas multiagente basados en LLMs aplicados a tareas de razonamiento aritmético, de sentido común y simbólico.
Intervención / Propuesta	MCF combina diálogo entre agentes, filtrado colaborativo y un repositorio de experiencias: 1. Diálogo entre agentes: los roles *User* y *Assistant* resuelven la tarea paso a paso, usando el contenido del paso anterior como entrada del siguiente. 2. Filtrado colaborativo multirrol: se configuran varias instancias con la misma meta para activar el espacio de respuestas del LLM, y una instancia adversarial sirve como referencia para el cálculo de similitud. 3. Cálculo de similitud: considera la similitud semántica, el historial del diálogo y la representación AMR del texto (estructura de la oración y palabras clave). 4. Repositorio de experiencias: almacena los procesos de razonamiento de tareas anteriores y los recupera ante tareas similares, descartando experiencias irrelevantes mediante detección de valores atípicos por Z-score.

Campo	Información Extraída
Resultados Principales	En el ejemplo de los autores, de 32 trayectorias de razonamiento muestreadas solo 12 llegaron a la respuesta correcta, lo que evidencia la variabilidad del espacio de respuestas. En el estudio de ablación con GPT-3.5-Turbo-0613, la precisión promedio aumentó de 83,0 % (diálogo entre agentes) a 84,7 % con el método AMR. En la comparación con métodos existentes usando GPT-3.5-Turbo-0613, MCF obtuvo el mejor resultado en 7 de 10 conjuntos de datos.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Comunicación centralizada y mediada, por turnos. El *Task Specifier* entrega la tarea detallada a los roles *User* y *Assistant*, que dialogan sobre un historial compartido; en cada paso, el mecanismo de filtrado colaborativo selecciona, entre las respuestas de las instancias de cada rol, la que continúa el diálogo.
Métricas reportadas	1. Precisión (*accuracy*): métrica principal, reportada en diez conjuntos de datos de razonamiento aritmético, de sentido común y simbólico. 2. Similitud semántica: utilizada para comparar las respuestas normales con la respuesta adversarial durante el filtrado. 3. Coincidencia de grafos AMR: mide el grado de coincidencia estructural entre respuestas, considerando la estructura de la oración y las palabras clave.
Tipos de fallo colectivo considerados	Alucinaciones de razonamiento (contenido que se desvía de las instrucciones o de los hechos) y acumulación continua de errores a lo largo de los pasos del razonamiento cuando la validez de cada paso no se verifica.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El estudio es metodológicamente sólido: evalúa diez conjuntos de datos y cuatro modelos, e incluye estudios de ablación que aíslan el aporte de cada módulo. Su aporte central para la revisión es verificar cada paso del razonamiento en lugar de evaluar solo la respuesta final, lo que ataca directamente la acumulación de errores. Sin embargo, la mejora del filtrado es acotada (de 83,0 % a 84,7 % de precisión promedio), y los autores no cuantifican el costo de inferencia que reconocen como limitación.
Limitaciones / Sesgos	Los autores señalan que, aunque MCF supera ampliamente a CoT, los costos y la eficiencia de la inferencia se vuelven consideraciones relevantes.
Conclusión del Autor	Los autores concluyen que MCF activa el espacio de respuestas de los LLMs mediante múltiples agentes e identifica la solución óptima en cada paso a través de instancias opuestas, y que la recuperación basada en Z-score mejora el uso del repositorio de experiencias al evitar el impacto negativo de recuperar experiencias irrelevantes.
Impresión del Estudiante	⋆⋆⋆⋆ **(Bueno).** Es pertinente para la PI3, porque propone un mecanismo concreto para contener la propagación de alucinaciones entre pasos, y en menor medida para la PI1, porque hace visible el razonamiento intermedio. No aborda la atribución del aporte individual de cada agente.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.