FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Chen R and He C (2025) Fostering collective intelligence in CPSS: an LLM-driven multi-agent cooperative tuning framework. *Front. Phys. 13:1613499*. DOI: 10.3389/fphy.2025.1613499	D-05	2025

Tipo de Estudio	Base de Datos	Indexación
Propuesta metodológica.	Frontiers	Scopus y Web of Science

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	El objetivo del estudio es presentar MACT, un framework cooperativo multiagente de refinamiento para entrenar múltiples LLMs en conjunto, para que la optimización de cada agente se alinee con el objetivo global.
Problema / Brecha	La mayoría de los acercamientos sólo usan las capacidades existentes de los LLM por separado, y fallan a la hora de mejorar su rendimiento en resolución de problemas cooperativamente. Además, discuten que la colaboración efectiva debe realizarse no sólo en la entrada (cuando comparten información) si no que debe ser enfocada a que mejoren como equipo.
Metodología	Primero introducen el framework MACT, delineando su método de resolución de problemas. Luego, introducen su metodología de entrenamiento, dividido en objetivos de optimización para un agente individual y los objetivos de optimización cooperativos multiagente.
Población / Ámbito	Área tecnológica de los sistemas multiagente basados en Grandes Modelos de Lenguaje aplicados a la resolución cooperativa de problemas.

Campo	Información Extraída
Intervención / Propuesta	MACT funciona así: Una cantidad N de agentes generan respuestas iterativamente para una tarea X por una cantidad T de rondas de comunicación. Luego, cada agente interactua con otros mediante prompts construidos dinámicamente basandose en los outputs de todos los agentes de la ronda previa. Todos los agentes cuentan con una red de crítica compartida, y se optimizan en conjunto mediante la función de perdida diseñada por la red de mezcla. 1. La política de LLM observa el estado de la conversación actual y las acciones en ejecución. 2. La red crítica LLM estima el valor actual. 3. La red de un solo agente optimiza su política LLM maximizando la recompensa obtenida, con el fin de alcanzar su óptimo individual. 4. Simultáneamente, los valores estimados por las redes críticas de todos los agentes son agregados a través de la red de mezcla para calcular el valor total del sistema en ese paso. 5. La red de mezcla se encarga de asegurar que el valor individual de cada agente mantenga una consistencia monotónica con el valor total del equipo. Esto significa que cuando cada agente maximiza su propio valor, el valor total también se maximiza, obligando a que los agentes se complementen entre sí y contribuyan efectivamente a la tarea.
Resultados Principales	Los autores demuestran que el marco MACT supera a los modelos individuales y métodos de debate, logrando mejoras de precisión de hasta un 17 % en el conjunto de datos GSM8K y 6.2 % en MATH. Se confirma que este enfoque optimiza la colaboración global, mitiga la propagación de errores dependientes del contexto.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Estructura de comunicación dinámica y en red, donde los agentes interactúan iterativamente a lo largo de múltiples rondas. En cada ronda, la comunicación opera de forma cruzada, ya que el prompt de un agente se construye integrando las respuestas de todos los demás agentes de la ronda anterior. Adicionalmente, para el entrenamiento, se utiliza una configuración centralizada donde una red de mezcla agrega las valoraciones de cada agente para la optimización global
Métricas reportadas	1. Precisión: Es la métrica de rendimiento principal, que evalúa la exactitud y tasa de éxito del sistema para resolver problemas lógicos y matemáticos en los conjuntos de datos de prueba GSM8K y MATH. 2. Consumo de memoria GPU: Una métrica de eficiencia que se utiliza para evaluar el impacto y los requerimientos computacionales del ajuste fino supervisado, el entrenamiento de la red crítica y los procesos de inferencia. 3. Tiempo de procesamiento: Métrica para contabilizar la duración de las distintas fases de entrenamiento y el tiempo de inferencia al procesar grandes lotes de datos. 4. Rondas de colaboración: El número de iteraciones o turnos de debate y cómo impacta en el rendimiento general del modelo, evaluando si el aumento de interacciones beneficia la precisión o si causa propagación de errores por límites de longitud. 5. Recompensa de coincidencia: Utilizada en el algoritmo de aprendizaje por refuerzo, la cual asigna un valor de 1 si la salida generada coincide exactamente con la respuesta correcta estándar y 0 en caso contrario.
Tipos de fallo colectivo considerados	Se estudian fallos como la repetición redundante de puntos de vista y la propagación de información incorrecta provocada por la excesiva dependencia del contexto entre agentes. También reporta degradación del rendimiento y fallos de resolución cuando las interacciones prolongadas superan las restricciones de longitud de los modelos.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El estudio es relevante en generalidad para LLM-MAS, y la metodología es ordenada y clara de entender.
Limitaciones / Sesgos	Las principales limitaciones incluyen la potencial ineficiencia y el elevado costo computacional que genera el uso exclusivo de lenguaje natural para la comunicación entre agentes.
Conclusión del Autor	Demuestran una mejora significativamente la capacidad de resolución de problemas de los agentes LLM, superando ampliamente a los enfoques previos. Destacan que este avance ofrece oportunidades más precisas para modelar el comportamiento humano en los Sistemas Ciber-Físico-Sociales.
Impresión del Estudiante	⋆⋆⋆ **(Bueno).** Es un paper atingente al tema general de agentes LLM-MAS.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.