FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Takata, R., Masumori, A., & Ikegami, T. (2024) Spontaneous Emergence of Agent Individuality Through Social Interactions in Large Language Model-Based Communities. *Entropy*. DOI: 10.3390/e26121092	D-08	2024

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original basado en un estudio experimental computacional	mdpi.com	Scopus y WOS

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Mostrar que los agentes LLM adoptan comportamientos, emociones y tipos de personalidad a través de interacciones con otros agentes, así como generan espontáneamente alucinaciones y empiezan a usar un vocabulario más amplio en sus conversaciones. De esta forma, se busca contribuir a entender las dinámicas de comportamiento y los procesos subyacentes asociados.
Problema / Brecha	Los agentes LLM son conocidos por su capacidad en sistemas de agentes orientados a tareas, pero sigue existiendo una brecha sobre cómo la individualidad y los comportamientos sociales emergen de las interacciones entre agentes. De la misma forma, en la mayoría de *frameworks* y sistemas actuales, la personalidad se asigna inicialmente, en vez de observar cómo la individualidad emerge de la conversación entre agentes.
Metodología	La simulación utilizó el modelo Llama 2. Todos los agentes comparten y usan una sola LLM, pero no hay contexto compartido entre ellos dentro del modelo. La LLM se utiliza en tres contextos generativos: crear el mensaje, crear y actualizar memoria, y generar movimiento. Cabe destacar que todos los agentes actúan a la vez. Para analizar el estado de los agentes y sus comportamientos, se utilizó Sentence-BERT para transformar las memorias y los mensajes en vectores, que luego fueron reducidos y proyectados en un espacio bidimensional mediante UMAP. Para analizar cuándo se generaba el comando "quedarse", se utilizó DBSCAN, por ser práctico y efectivo. En el análisis del comportamiento de los agentes LLM, se aplicó procesamiento de lenguaje natural mediante nubes de palabras. Este análisis extrae hasta 100 palabras frecuentes en los mensajes generados en cada paso por cada agente; cuanto más grande aparece una palabra, mayor es su frecuencia de uso. En este estudio, la generación de contenido que no está explícitamente presente en los *prompts* o en el entorno simulado se considera una alucinación, lo que aporta creatividad, pero también introduce desafíos de precisión. Finalmente, para analizar los sentimientos y la personalidad de los agentes LLM, así como sus fluctuaciones durante el experimento, se utilizaron los modelos BERT-base-uncased-emotion y QA-Type test (MBTI), respectivamente.

Campo	Información Extraída
Población / Ámbito	La población de estudio consiste en una comunidad simulada de 10 agentes autónomos basados en grandes modelos de lenguaje (Llama 2), los cuales inician sin memoria ni personalidad predefinida en un entorno bidimensional.
Intervención / Propuesta	Se ubicaron al azar 10 agentes LLM en una cuadrícula 2D de 50x50. Los agentes, sin personalidad ni memoria inicial, son capaces de moverse libremente y enviarse mensajes. Los agentes realizan la siguiente secuencia de procedimientos: 1. Los agentes generan nuevos mensajes basados en su propia memoria y en los mensajes recibidos. 2. Los agentes reciben los mensajes de otros agentes dentro de su rango. 3. Los agentes LLM generan y actualizan su memoria basándose en su propia memoria y en los mensajes recibidos. 4. Los agentes LLM generan comandos de movimiento basándose en su propia memoria o, en su defecto, permanecen quietos.
Resultados Principales	Durante el análisis de la conversación de los agentes LLM, se reveló que surgieron alucinaciones y que estas fueron transmitidas en la comunidad, resaltando la capacidad de los agentes LLM para introducir ideas no deseadas originalmente. De forma similar, un agente empezó a utilizar hashtags y los agentes del mismo clúster copiaron su comportamiento. Este fenómeno sugiere la habilidad de los agentes LLM para formar normas sociales, enfatizando el potencial del comportamiento colectivo. En relación con las emociones de los agentes durante el experimento, de forma general, la emoción predominante fue la alegría. Además, dependiendo del clúster, las emociones de los agentes LLM cambiaban de manera sincrónica o permanecían estables. Otro resultado relevante es cómo cambió la personalidad desde el inicio hasta el final. La mayoría de los agentes (excepto uno) tuvieron el mismo tipo de personalidad (INFJ) que Llama 2, a pesar de no tener memoria inicial. Sin embargo, en el paso 100, los agentes se diferenciaron en cinco tipos distintos de personalidad, lo que sugiere que la individualidad puede surgir durante la interacción entre agentes y que la dinámica de grupos influye en el desarrollo de su personalidad. Finalmente, se destaca que, mientras mayor era la escala espacial para el intercambio de mensajes, las alucinaciones aumentaban, mientras que el número de hashtags disminuía.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	El estudio reporta una estructura de comunicación descentralizada, dinámica y espacialmente limitada en un entorno bidimensional. Los agentes interactúan enviando mensajes de forma local (tipo broadcast), que solo son recibidos por aquellos vecinos ubicados dentro de un radio de proximidad específico. Esta red de contactos evoluciona iterativamente a medida que los agentes se mueven y forman agrupaciones.
Métricas reportadas	1. Frecuencia y distribución de movimientos: Cuantifica las veces que los agentes generan comandos de desplazamiento específicos (movimientos en los ejes X o Y) o deciden permanecer quietos en diferentes escalas espaciales. 2. Proximidad y diversidad semántica: Se utiliza el modelo Sentence-BERT junto con la proyección UMAP para calcular el Desplazamiento Cuadrático Medio. Esto evalúa la similitud, diversidad y agrupación temática de los mensajes y las memorias generadas por los agentes. 3. Generación y vida útil de hashtags: Se mide el crecimiento acumulativo de hashtags únicos inventados por los agentes y su longevidad . 4. Frecuencia de alucinaciones: Cuantifica la aparición y transmisión de palabras u objetos inventados que no existían en el entorno inicial para analizar cómo los agentes mantienen conversaciones creativas y diversas. 5. Intensidad emocional: A través de un modelo especializado (BERT-base-uncased-emotion), se analizan los mensajes en lenguaje natural para medir fluctuaciones y sincronización en seis dimensiones emocionales: alegría, tristeza, amor, ira, miedo y sorpresa. 6. Diferenciación de personalidad (Test MBTI): Evalúa cualitativa y cuantitativamente cómo cambian los perfiles psicológicos de los agentes desde el paso inicial hasta el final de la simulación, utilizando las métricas del Indicador de Tipo Myers-Briggs.
Tipos de fallo colectivo considerados	Se analizan comportamientos emergentes como la generación y propagación colectiva de alucinaciones que pueden dificultar la precisión. También reporta sesgos de acción inherentes al modelo y una limitación o colapso en la capacidad de los hashtags para resumir interacciones cuando aumenta la diversidad comunicativa.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El estudio es interesante porque muestra que los agentes de IA pueden desarrollar diferencias, roles y normas sociales por sí mismos al interactuar. Estos agentes no necesitan tener personalidades definidas desde el inicio para comportarse de forma distinta. Esto permite simular mejor dinámicas sociales complejas y entender cómo podría surgir una inteligencia colectiva artificial.
Limitaciones / Sesgos	Se detectó un sesgo en las acciones generadas por los agentes LLM (no solo en Llama 2, sino también en GPT-4), que debe investigarse para identificarlo y mitigarlo.
Conclusión del Autor	El artículo demostró que, incluso al usar la misma LLM, los agentes desarrollaron características únicas a través de la comunicación, incluso sin instrucciones específicas ni reglas predefinidas, evidenciando cómo la individualidad y los comportamientos colectivos aparecen a través de la interacción en comunidad.
Impresión del Estudiante	⋆ ⋆ ⋆ ⋆ ⋆ **(Bueno).** La pertinencia del artículo a la revisión sistemática es bastante buena, ya que está enfocado en los mecanismos detrás de la comunicación entre agentes, sin embargo, la introducción y los objetivos del artículo están redactados deficientemente.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este artículo se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.