# FICHA DE EXTRACCIÓN DE INFORMACIÓN
## (REVISIÓN SISTEMÁTICA)

**Guía Universitaria (UNAP)** | Basado en Mian *et al.* (2005) & PRISMA

---

## 1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

| Referencia | ID Hoja | Año |
|---|---|---|
| Zheng, L., Chen, J., Yin, Q., Zhang, J., Zeng, X., & Tian, Y. (2026). Rethinking the Reliability of Multi-agent System: A Perspective from Byzantine Fault Tolerance. *Proceedings of the AAAI Conference on Artificial Intelligence*. DOI: 10.1609/aaai.v40i41.40806 | D-09 | 2026 |

| Tipo de Estudio | Base de Datos | Indexación |
|---|---|---|
| Artículo de investigación original que integra una propuesta metodológica y un estudio experimental. | Association for the Advancement of Artificial Intelligence (AAAI) | Scopus |

## 2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

| Campo | Información Extraída |
|---|---|
| **Objetivo (Intención)** | El objetivo del estudio es investigar y cuantificar la fiabilidad de los agentes basados en LLM desde la perspectiva de la tolerancia a fallas bizantinas. |
| **Problema / Brecha** | Los autores destacan como brecha principal las implicaciones en fiabilidad de los agentes LLM integrados en MAS, es decir, si sustituir agentes tradicionales con agentes basados en LLMs puede efectivamente mejorar la fiabilidad de un sistema multi-agente. |
| **Metodología** | En primer lugar, los autores diseñaron una serie de experimentos piloto para investigar la fiabilidad de agentes LLM desde la perspectiva de la tolerancia a fallas bizantinas. Obtuvieron como resultado que los agentes basados en LLM exhibían mayor confiabilidad comparados con agentes tradicionales, en distintas topologías de red.<br>Basados en los resultados obtenidos, propusieron el framework CP-WBFT, un mecanismo de consenso tolerante a fallas bizantinas ponderado y basado en pruebas de confianza.<br>Se evaluó CP-WBFT en 6 topologías de red: grafo completo, estrella, árbol, cadena, grafo aleatorio y grafo con capas. Cada red consistía en 7 nodos, siendo 6 agentes bizantinos (maliciosos) y 1 honesto. Se realizaban 10 experimentos (razonamiento matemático GSM8K y evaluación de riesgos XSTest) por cada topología de red.<br>Como métrica principal está la Mejora de Tolerancia a Fallos Bizantina (BFTI), que mide cuán efectivamente la inteligencia colectiva mejora la fiabilidad de agentes individuales. |
| **Población / Ámbito** | La población del estudio consiste en redes de 7 agentes basados en LLMs (como los modelos LLaMA3 y GPT) organizados a través de seis topologías de red distintas. |

| Campo | Información Extraída |
|---|---|
| **Intervención / Propuesta** | CP-WBFT es un mecanismo de consenso tolerante a fallas bizantinas ponderado y basado en pruebas de confianza, cuyo objetivo es mejorar la estabilidad de los sistemas multiagentes en distintas topologías.<br>1. Primero, desarrollaron sondas de confianza desde dos perspectivas: la del prompt y la del decodificador, para evaluar el nivel de confianza del agente.<br>▪ Prueba de confianza a nivel de prompt: Aprovecha la naturaleza autorreflexiva de los LLM para que el agente cuantifique su certeza.<br>▪ Prueba de confianza a nivel oculto: Se investiga la confianza de la respuesta, extrayendo y cuantificando la fiabilidad de representaciones en capas ocultas de los LLM.<br>2. Luego diseñaron el protocolo de consenso bizantino guiado por fiabilidad, que mejora la confiabilidad de los agentes basados en LLM, asignando dinámicamente mayor peso de transmisión de la información a los agentes con más fiabilidad. Consiste en un proceso de dos fases:<br>▪ Primero se les permite a los agentes refinar su decisión local mediante la adopción de respuestas vecinas que tengan mayor nivel de confianza que la propia.<br>▪ Luego, el consenso agrega las respuestas refinadas seleccionando la respuesta con mayor confianza promedio, utilizando la cantidad de agentes que la apoyan como criterio de desempate. |
| **Resultados Principales** | El HCP permitió un consenso fiable consistentemente, superando en rendimiento a otros métodos en diferentes tareas y topologías de red. Además, resaltaron que la topología de red impactaba en el consenso, siendo los grafos completos los que maximizaban el flujo de información. Finalmente, a pesar de que las características de las tareas influyen en la utilidad de métodos de extracción de confianza, HCP exhibió solidez independientemente de la tarea. |

## 3. VARIABLES ESPECÍFICAS DE ANÁLISIS

| Pregunta / Variable | Respuesta Extraída |
|---|---|
| **Topología de comunicación empleada** | El estudio evalúa de forma comparativa múltiples topologías de red, incluyendo configuraciones secuenciales (cadena), jerárquicas (árbol), en estrella, grafos en capas, aleatorios y redes completas. En estas estructuras, los agentes interactúan intercambiando mensajes con sus vecinos para alcanzar un consenso colectivo, utilizando un flujo de información ponderado según sus niveles de confianza. |
| **Métricas reportadas** | 1. Precisión a nivel de ronda: Es la métrica principal adoptada para evaluar la confiabilidad de los agentes basados en LLM en cada iteración.<br>2. Precisión inicial del agente: Mide el rendimiento o precisión del agente antes de que se apliquen los mecanismos de tolerancia a fallos.<br>3. Precisión final del agente: Cuantifica la precisión del sistema después de haber aplicado el procesamiento y los consensos de tolerancia a fallos bizantinos.<br>4. Mejora de la Tolerancia a Fallos Bizantinos: Mide la mejora porcentual obtenida al pasar de la precisión inicial a la precisión final. Esta métrica sirve para cuantificar con qué eficacia la inteligencia colectiva mejora la confiabilidad individual de un agente.<br>5. Precisión, Valor predictivo positivo, Puntuación F1 y Área bajo la curva : Conjunto de métricas estadísticas utilizadas específicamente para analizar y evaluar la calidad de la calibración de confianza de los modelos. |
| **Tipos de fallo colectivo considerados** | Se analizan fallos en cascada, degradación del rendimiento y colapso total del sistema desencadenados por el comportamiento anómalo o malicioso de agentes individuales (nodos bizantinos). Además, examina la propagación de información errónea y la pérdida de consenso derivadas de estas vulnerabilidades, destacando cómo ciertas topologías de red restringidas pueden exacerbar la incapacidad de llegar a un acuerdo. |

## 4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

| Campo | Valoración del Investigador |
|---|---|
| **Valoración del Investigador** | El paper es relevante; sin embargo, me quedé con la impresión de que la redacción del mismo pudo haber sido mejor, de manera que se facilitase la comprensión y el verdadero objetivo. |
| **Limitaciones / Sesgos** | El estudio presenta un alto costo computacional debido al constante intercambio iterativo de información entre los agentes. Además, muestra una fuerte dependencia de la topología de la red en tareas de seguridad, lo que limita la efectividad del consenso en estructuras con conexiones restringidas. |
| **Conclusión del Autor** | Los autores concluyen que su hipótesis fue validada por los resultados: las representaciones internas del modelo proveen buenos indicadores de fiabilidad para la tolerancia a fallos bizantina. Finalmente, declaran que el buen rendimiento de CP-WBFT ante situaciones adversas demuestra el potencial práctico de consenso guiado por confianza en configuraciones multiagente del mundo real. |
| **Impresión del Estudiante** | ⋆⋆ **( Regular).** Sirve, porque se interesa en una posible solución para minimizar errores en sistemas MAS-LLM, sin embargo, no aplica a una pregunta de investigación directamente. |

## 5. OBSERVACIONES GENERALES Y NOTAS

*N* Nota

**Nota principal:** Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

**Relación con la revisión sistemática:** Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.