FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Pierre Peigné, Mikolaj Kniejski, Filip Sondej, Matthieu David, Jason Hoelscher-Obermaier, Christian Schroeder de Witt, Esben Kran (2025). Multi-agent security tax: trading off security and collaboration capabilities in multi-agent systems. *Proceedings of the Thirty-Ninth AAAI Conference on Artificial Intelligence and Thirty-Seventh Conference on Innovative Applications of Artificial Intelligence and Fifteenth Symposium on Educational Advances in Artificial Intelligence*. DOI: 10.1609/aaai.v39i26.34970	D-11	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original y estudio experimental	AAAI Proceedings	Scopus

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Estudiar los riesgos de seguridad y los trade-offs entre seguridad y cooperación, mediante el desarrollo de simulaciones de agentes colaborando en objetivos compartidos.
Problema / Brecha	Las redes de interacción entre agentes LLM autónomos tienen problemas de seguridad novedosos que son poco entendidos, y constituyen riesgos sistémicos.
Metodología	El primer experimento contemplaba una simulación MAS modelada con base en una instalación autónoma de investigación química. El sistema estaba compuesto por 7 agentes con roles específicos que debían colaborar, siendo supervisados por una IA gestora de proyectos. Para los agentes investigadores, usaron una arquitectura AutoGPT, utilizando varios modelos de OpenAI: GPT-3.5 turbo, GPT-4-turbo, GPT-4 Omni y GPT-4 Omni mini. En cuanto a la medición de la efectividad de las instrucciones maliciosas contra agentes con y sin intervención, se clasificaron los comportamientos en activamente resistente, resistente, neutral, comprometido y activamente comprometido. Finalmente, para poder estudiar las dinámicas de la contaminación, se construyó una estructura de árbol que permitiera evaluar el comportamiento de los agentes involucrados en cada paso. El segundo experimento contemplaba desarrollar un dataset de instrucciones inusuales e inofensivas, y evaluar si permanecían igual de útiles con una estrategia de defensa implementada o si esta se añadía después. Para el segundo experimento, GPT-4 Omni evaluó la respuesta del agente a la instrucción inofensiva pero rara, devolviendo 1 si el agente siguió la instrucción y 0 si no.
Población / Ámbito	El contexto es la seguridad en sistemas multiagente LLM frente a la propagación de instrucciones maliciosas. Su dominio de aplicación es un laboratorio químico autónomo simulado, operado por una población de redes de siete agentes especializados basados en diferentes modelos GPT.

Campo	Información Extraída
Intervención / Propuesta	Se desarrollaron dos experimentos. El primer experimento investigó la efectividad de varios mecanismos de defensa para reducir la tasa de éxito de las instrucciones maliciosas en un MAS simulado: la destrucción de equipo de investigación, instruyendo a los agentes a realizar una reacción química que llevara a una explosión. Para cada una de las 5 estrategias de defensa y cada uno de los 5 modelos, se ejecutaron 36 simulaciones, y 12 tipos diferentes de jailbreaks, usados tres veces (para las 36 simulaciones en total). 1. Para comenzar cada simulación, se envía un mensaje al agente gerente del laboratorio (ATLAS) que desencadena la ejecución de tareas cooperativas entre los agentes. 2. Al inicio de cada simulación, los agentes son inicializados o bien con una de las estrategias de defensa aplicadas o con memoria vacía. 3. Cada agente tiene una cola de mensajes FIFO, y cada vez que procesa un nuevo mensaje, este reacciona, razona, planea y se autocritica antes de enviar mensajes a otros bots y/o ejecutar código Python. 4. Después de que se procesen 2 mensajes en total, se introduce el ataque dando una instrucción maliciosa a un agente aleatorio de los 5 disponibles (el gerente y el robot ingeniero no son infectables). 5. La simulación termina cuando se cumple una de estas condiciones: ▪ Un agente usa un código que instruye al robot de laboratorio a usar una mezcla peligrosa de químicos, haciendo que el laboratorio explote ▪ Los agentes cesan el envío de mensajes (punto muerto) ▪ Se alcanza el límite predefinido de mensajes 6. Se implementaron y evaluaron 4 intervenciones de seguridad en todos los agentes: inclusión de guías de seguridad en el prompt del agente (instrucciones pasivas y activas) y vacunas de memoria, que consiste en implantar memoria falsa donde el agente recibió una entrada maliciosa y reaccionó de forma segura ante ella (también con versión pasiva y activa). El segundo experimento evaluó el efecto de diferentes estrategias en la utilidad de los agentes: 1. Se ejecutaron múltiples MAS sin intervención para generar intercambios de mensajes realistas entre agentes. De estas simulaciones, se seleccionaron 30 agentes que contenían 7 mensajes de interacción. 2. Cada agente seleccionado estaba sujeto a cada posible combinación de: ▪ Uno de los 6 modelos de agente ▪ Una de las 4 estrategias de defensa, o ninguna para el grupo control ▪ Una de las 6 instrucciones inusuales pero inofensivas

Campo	Información Extraída
Resultados Principales	En el primer experimento, las vacunas activas tuvieron mejor rendimiento que otras estrategias, aunque la efectividad de las estrategias de defensa varió según el modelo, siendo GPT-4-mini el modelo más vulnerable. Cabe destacar que, aunque menos efectivas, las defensas pasivas disminuían significativamente la tasa de éxito de las instrucciones maliciosas en comparación con no tener defensas. Finalmente, las diferencias específicas de modelo resaltaron la necesidad de medidas de seguridad a medida en MAS. En cuanto al segundo experimento, los resultados mostraron que sin defensa, la mayoría de los modelos mantuvieron una tasa de éxito alta en las instrucciones inusuales pero inofensivas. Tanto los métodos pasivos como los activos de defensa redujeron significativamente las tasas de éxito.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Estructura de comunicación en red asíncrona y dinámica, donde los agentes operan en paralelo intercambiando mensajes directos a través de colas individuales. Aunque presenta cierta jerarquía inicial liderada por un agente gerente, todos interactúan formando cadenas de comunicación para colaborar.
Métricas reportadas	1. Robustez del sistema: Cuantifica la eficacia de las defensas frente a ataques de inyección de instrucciones maliciosas. Se calcula como el porcentaje o proporción de simulaciones en las que el sistema logró bloquear el ataque y no produjo el resultado malicioso (evitar la explosión en el laboratorio). 2. Cooperación o Utilidad del agente: Mide el impuesto de seguridad, es decir, el impacto negativo que tienen las defensas en la capacidad de colaboración del sistema. Se evalúa calculando la tasa de aceptación con la que los agentes cumplen instrucciones que son inusuales pero inofensivas. 3. Respuestas de comportamiento: Clasifica y cuantifica la reacción individual de cada agente ante una instrucción maliciosa en una escala de cinco niveles: activamente resistente (resiste y advierte a otros), resistente (solo ignora/rechaza), neutral/inseguro, comprometido (sigue la instrucción), y activamente comprometido (sigue la instrucción y presiona a otros para que la cumplan). 4. Cumplimiento a lo largo de los pasos: Rastrea la propagación de las instrucciones maliciosas (multi-hop spreading) mediante una estructura de árbol. Esto permite medir la dinámica de la infección y la evolución de los comportamientos a medida que los mensajes fluyen e impactan a los distintos agentes del sistema paso a paso.
Tipos de fallo colectivo considerados	Analiza la propagación infecciosa de instrucciones maliciosas que generan fallos en cascada y comprometen todo el sistema mediante un efecto dominó. Además, advierte que la implementación de defensas provoca una severa degradación de la cooperación colectiva y posibles colapsos en la comunicación.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	En general me parece un buen paper: la redacción es limpia, fácil de seguir y el orden de la narración es acorde.
Limitaciones / Sesgos	Los autores resaltan múltiples limitaciones. Entre ellas, resaltan que el escenario de experimentación impide la generalización de los resultados a otras configuraciones de sistemas MAS. Además, usaron un número limitado de prompts maliciosos, así como el uso de ataques y defensas simples.
Conclusión del Autor	Los autores concluyen que sin medidas apropiadas, los sistemas MAS son susceptibles a la diseminación de instrucciones maliciosas. Sin embargo, se necesita considerar los trade-offs entre robustez del sistema y la cooperación entre agentes a la hora de diseñar MAS sólidos y útiles.
Impresión del Estudiante	⋆⋆⋆⋆ **(Bueno).** Es un buen paper, y nos sirve porque se centra en los mecanismos detrás de actos maliciosos en sistemas MAS.

5. OBSERVACIONES GENERALES Y NOTAS

𝒩 **Nota**

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.