FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Han, C., Ma, Y., Tan, J., Zheng, W., & Tang, X. (2026). Beyond Detection: Exploring Evidence-based Multi-Agent Debate for Misinformation Intervention and Persuasion. *Proceedings of the AAAI Conference on Artificial Intelligence, 40(45), 38542–38550.*. DOI: 10.1609/aaai.v40i45.41196	D-14	2026

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original que integra tanto una propuesta metodológica como un estudio experimental.	AAAI	Scopus

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Presentar ED2D, un framework de debate multi-agente basado en evidencia diseñado no solo para detectar desinformación, sino también para actuar como un sistema persuasivo capaz de corregir las creencias de los usuarios y disuadir su propagación.
Problema / Brecha	Los autores resaltan la vulnerabilidad a alucinaciones en los sistemas actuales de detección de desinformación al depender exclusivamente del conocimiento interno del modelo.Además, la falta de marcos basados en evidencia externa enfocados no solo en clasificar la información pasivamente, sino en ofrecer razonamientos persuasivos para corregir proactivamente las creencias erróneas de los usuarios.
Metodología	Se basa en el diseño e implementación de ED2D, un marco de debate multi-agente impulsado por el modelo GPT-4o, estructurado en cinco etapas de interacción (apertura, refutación, debate libre, cierre y juicio) e integrado con un módulo automático de recuperación de evidencia externa mediante una API de Wikipedia para sustentar los argumentos y mitigar alucinaciones. Para evaluar el sistema, los investigadores combinan pruebas computacionales y estudios empíricos con usuarios. Computacionalmente, analizan la precisión de detección de ED2D frente a modelos base tradicionales (como BERT y RoBERTa) y diversas estrategias de prompting para LLM utilizando tres conjuntos de datos: Weibo21, FakeNewsDataset y un nuevo benchmark propio llamado Snopes25. Adicionalmente, ejecutan un experimento controlado con 200 participantes humanos asignados aleatoriamente a diferentes condiciones (grupo control, explicaciones generadas por ED2D, verificaciones de expertos de Snopes y un grupo combinado), mediante el cual evaluaron la eficacia persuasiva del sistema utilizando cuestionarios de escala Likert y modelos estadísticos de regresión de efectos mixtos.
Población / Ámbito	Área tecnológica de la Inteligencia Artificial aplicada a la detección e intervención de desinformación, evaluando el impacto persuasivo de un sistema multiagente en una población experimental de 200 usuarios angloparlantes.

Campo	Información Extraída
Intervención / Propuesta	Este framework organiza un debate estructurado entre agentes de inteligencia artificial con posturas opuestas, evaluado por un panel de jueces que emite un veredicto final respaldado por un resumen transparente, persuasivo y basado en hechos comprobables: 1. El sistema gestiona la interacción a través de cinco etapas secuenciales: Apertura, Refutación, Debate Libre, Cierre y Juicio, empleando una memoria compartida comprimida por etapas para mantener la coherencia a lo largo de los múltiples turnos. 2. La capa de agentes configura un equipo Afirmativo y uno Negativo; cada uno está compuesto por agentes LLMs con perfiles específicos de dominio que defienden colaborativamente una postura preasignada. 3. Durante la fase de Debate Libre, el sistema extrae entidades clave de la afirmación original, busca información factual en Wikipedia mediante una API, clasifica la postura de la evidencia (apoyo, refutación o neutral) y la integra directamente en los argumentos de los debatientes. 4. Agentes observadores evalúan el diálogo completo puntuando cinco dimensiones: Factualidad, Confiabilidad de la fuente, Calidad del razonamiento, Claridad y Consideraciones éticas. Utilizan un esquema de puntuación complementario que imposibilita los empates. 5. En su etapa final, ED2D emite una etiqueta binaria de veracidad (REAL o FALSO) y genera un resumen estructurado del debate que destaca los argumentos principales y las refutaciones basadas en evidencia, facilitando la interpretabilidad y el impacto persuasivo en el usuario final.
Resultados Principales	Los resultados muestran que ED2D supera en precisión y puntuación F1 a modelos base y diversas estrategias de LLMs en tres conjuntos de datos de prueba. Además evidencian que sus explicaciones correctas alcanzan una eficacia persuasiva equiparable a la de expertos humanos para corregir creencias, aunque advierten que si el modelo falla, corre el riesgo de reforzar la desinformación en los usuarios.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Comunicación orquestada y secuencial, gestionada centralmente por una capa que programa los turnos a lo largo de cinco etapas estructuradas de debate. Los agentes interactúan a través de una memoria compartida que comprime el historial del diálogo, permitiendo interacciones coherentes en múltiples turnos.
Métricas reportadas	1. Métricas de rendimiento de clasificación computacional: Para evaluar la detección de desinformación frente a otros modelos, los autores utilizaron métricas estándar de aprendizaje automático: Exactitud, Precisión, Recall y Puntuación F1. 2. Creencia en la afirmación: Mide la veracidad percibida de la afirmación por parte del usuario, actuando como la medida principal del cambio de creencias. 3. Disposición a compartir: Refleja el riesgo de difusión conductual al medir la probabilidad de que el usuario comparta la afirmación con otros. 4. Alineación emocional: Captura la resonancia afectiva midiendo el nivel de alineación percibida entre la afirmación y los valores personales del usuario. 5. Precisión posterior a la exposición: En el estudio con usuarios, también midieron el porcentaje de exactitud de los participantes al evaluar de forma independiente una nueva serie de afirmaciones sin material explicativo, con el fin de comprobar si la exposición previa al sistema mejoró sus habilidades para detectar desinformación. 6. Métricas internas de los agentes jueces: Dentro de la arquitectura del propio sistema, el panel de agentes que evalúa el debate califica la interacción basándose en cinco dimensiones predefinidas: Factualidad, Confiabilidad de la fuente, Calidad del razonamiento, Claridad y Consideraciones éticas.
Tipos de fallo colectivo considerados	Vulnerabilidad a las alucinaciones en los sistemas multiagente generada al depender exclusivamente de su conocimiento interno. Asimismo, advierte sobre la propagación de errores mediante la persuasión engañosa, un fallo donde las clasificaciones incorrectas del sistema refuerzan inadvertidamente las falsas creencias de los usuarios.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	Es un paper con una excelente metodología y distintos experimentos para comprobar su eficacia.
Limitaciones / Sesgos	El principal riesgo no resuelto radica en la persuasión engañosa, donde los fallos del sistema refuerzan la desinformación en los usuarios, dejando pendientes futuras mejoras en escalabilidad, razonamiento no binario y salvaguardias contra usos adversarios.
Conclusión del Autor	Los autores concluyen que el marco ED2D mejora significativamente la detección de desinformación y genera explicaciones tan persuasivas como las de expertos humanos. Sin embargo, advierten sobre un grave riesgo asociado: si el sistema se equivoca en su juicio, sus explicaciones pueden desviar engañosamente las creencias de los usuarios.
Impresión del Estudiante	⋆⋆⋆⋆ **(Excelente).** No se enfoca tanto en los mecanismos detrás de la comunicación, pero es un paper bastante completo en general.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Escribir aquí una observación importante sobre el artículo, por ejemplo una idea clave, una cita conceptual, una relación con tu tema de investigación o una advertencia metodológica.

Relación con la revisión sistemática: Explicar aquí cómo este paper se conecta con tus preguntas de investigación, criterios de inclusión/exclusión o categorías de análisis.