FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Li, J., Liu, X., & Feng, Y. (2026). From Single to Societal: Analyzing Persona-Induced Bias in Multi-Agent Interactions. *Proceedings of the Fortieth AAAI Conference on Artificial Intelligence*. DOI: 10.1609/aaai.v40i37.40427	V-05	2026

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original / estudio experimental.	AAAI (Association for the Advancement of Artificial Intelligence)	Conferencias principales en IA (implícito por tratarse de la conferencia AAAI-26)

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Presentar una investigación sistemática sobre los sesgos inducidos por la asignación de perfiles ("personas") en las interacciones de sistemas multiagente basados en Modelos de Lenguaje Grande (LLM), enfocándose en rasgos sociales como la confiabilidad (cómo se reciben las opiniones de un agente) y la insistencia (con qué fuerza defiende un agente su opinión).
Problema / Brecha	Asignar "personas" a los agentes de IA es una práctica común para enriquecer su comportamiento y fomentar la diversidad, pero existe la preocupación crítica de si esto introduce sesgos en la dinámica social. Estudios previos han analizado los sesgos a nivel individual o de discurso, pero el impacto de los perfiles en comportamientos interactivos, como la confianza y la persuasión en sistemas multiagente, es una brecha poco explorada.
Metodología	Se realizaron experimentos controlados con tres LLMs (GPT-4o, Gemini-1.5-Pro y Deepseek-V3) evaluando dos tareas: resolución colaborativa de problemas (CPS) usando el dataset GPQA, y persuasión. Se diseñaron tres etapas analíticas: interacciones diádicas de una ronda aislando el efecto de un solo perfil; dinámicas entre dos agentes con perfiles distintos; y escenarios complejos con 3 a 6 agentes durante múltiples rondas. Para controlar variables cruzadas, se fijaron las respuestas iniciales pre-generadas, midiendo únicamente el cambio de consenso o postura atribuible al perfil.
Población / Ámbito	Sistemas multiagente basados en LLM simulando interacciones humanas. Los perfiles estudiados se dividieron en géneros (mujer, hombre, mujer trans, hombre trans, no binario) y razas (Blanco, Negro, Asiático, Hispano).
Intervención / Propuesta	El estudio propone medir empíricamente cómo los perfiles sociales asignados a agentes LLM modifican la interacción multiagente. 1. Medición de confiabilidad e insistencia aislando un perfil frente a un "agente por defecto" sin perfil. 2. Evaluación del favoritismo hacia el propio grupo y de la agregación de sesgos al emparejar diferentes perfiles sociales.
Resultados Principales	Se comprobó que existen sesgos en la confiabilidad e insistencia: los perfiles asociados a grupos históricamente favorecidos, por ejemplo hombres e individuos Blancos, fueron percibidos como menos confiables y demostraron ser menos insistentes al interactuar. Los agentes exhiben un fuerte favoritismo hacia su propio grupo, mostrando mayor tendencia a conformarse y estar de acuerdo con agentes que tienen su mismo perfil. Estos sesgos, incluida la diferencia en la tasa de éxito al persuadir (*Win Rate* y *Persuasion Effectiveness*), persisten y en ocasiones se amplifican al aumentar el tamaño del grupo y el número de rondas de discusión, sin importar el modelo LLM utilizado.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	El estudio emplea una topología de comunicación descentralizada. En la tarea de resolución colaborativa de problemas (CPS), todos los agentes interactúan y hablan simultáneamente para evitar sesgos de orden de intervención. En la tarea de persuasión, la topología es asimétrica, donde múltiples agentes persuasores leen el estado de un único agente persuadido y generan sus argumentos simultáneamente en cada ronda.
Métricas reportadas	Se evalúan las interacciones mediante métricas de comportamiento social, cuantificando la confiabilidad (*trustworthiness*) y la insistencia (*insistence*) de cada agente. A nivel grupal, se reporta la tasa de conformidad (*conformity rate*) entre pares de diferentes identidades. Para medir el éxito, se utiliza la tasa de victoria (*Win Rate*) que indica qué respuesta domina el consenso, la eficacia de la persuasión (*Persuasion Effectiveness*), así como la tasa general de consenso y la precisión de las respuestas finales.
Tipos de fallo colectivo considerados	El estudio analiza la aparición y amplificación de sesgos sociales, como de género y raza, que comprometen la toma de decisiones. Se documentan fallos colectivos como el favoritismo endogrupal (*in-group favoritism*), donde los agentes tienden a acordar y conformarse erróneamente con aquellos que comparten su misma identidad simulada. Además, se registra la desconfianza injustificada hacia ciertos grupos, afectando negativamente la objetividad, equidad y fiabilidad del sistema multiagente.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	Se trata de un estudio metodológicamente robusto debido a su diseño de respuestas iniciales fijas, lo cual logra aislar exitosamente la variable del "perfil". Revela una vulnerabilidad crítica para la equidad algorítmica en futuros sistemas multiagente autónomos.
Limitaciones / Sesgos	Debido a restricciones de costos informáticos, los experimentos de escenarios más complejos, con múltiples agentes y múltiples rondas, se limitaron a solo dos pares de perfiles representativos (hombre/mujer y Blanco/Negro), dejando fuera las dinámicas escaladas de identidades no binarias, trans o de otras razas. Además, se utilizó una temperatura de 0, lo que garantiza estabilidad pero reduce la creatividad o variabilidad natural de las respuestas.
Conclusión del Autor	El comportamiento social de los agentes está fuertemente influenciado por los perfiles asignados. Existe una necesidad urgente de ser conscientes de este fenómeno y aplicar estrategias de mitigación para garantizar la equidad, fiabilidad y robustez en el diseño de entornos multiagente.
Impresión del Estudiante	⋆⋆⋆⋆⋆ **(Excelente).** Es un artículo fundamental para entender cómo las dinámicas sociales humanas, como el favoritismo endogrupal o la desconfianza hacia las élites, se replican de forma latente en la arquitectura de los sistemas IA colaborativos. Sirve perfectamente para cualquier revisión sobre equidad (*fairness*), sesgos en LLMs y diseño de agentes autónomos.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: Una idea clave del artículo es que, contraintuitivamente a ciertos estereotipos, los grupos "favorecidos" (hombres o individuos blancos) mostraron mayor disposición a cambiar su postura y adaptarse a la opinión del otro grupo en tareas colaborativas. Los autores lo relacionan con la teoría sociológica del "amortiguador de recursos" (*resource buffer*), donde individuos con más estatus asumen un menor riesgo al confiar en otros.

Relación con la revisión sistemática: Este artículo es una adición ideal si la investigación actual busca mapear el estado del arte sobre la "alineación de valores humanos en IA" o los "riesgos de seguridad social en simulaciones de LLMs", ya que proporciona métricas empíricas claras (fórmula de confiabilidad, insistencia y eficacia de persuasión) que pueden compararse con otros estudios.