FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Xiong, C., Zheng, G., Ma, X., Li, C., & Zeng, J. (2025). DelphiAgent: A trustworthy multi-agent verification framework for automated fact verification. *Information Processing & Management*, 62(6), 104241. DOI: 10.1016/j.ipm.2025.104241	V-09	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original / propuesta metodológica.	ScienceDirect / Elsevier — *Information Processing & Management*	Revista científica indexada

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Proponer *DelphiAgent*, un marco innovador basado en agentes para la verificación confiable de hechos que emplea múltiples LLMs para emular el flujo de trabajo del método Delphi, con el fin de mejorar la transparencia en la toma de decisiones y mitigar las alucinaciones.
Problema / Brecha	Los métodos basados en LLMs que no utilizan arquitecturas de agentes generan respuestas mediante *prompts* directos en un solo paso, lo que provoca problemas graves de alucinación y falta de factualidad. Por su parte, los métodos tradicionales supervisados carecen de transparencia, funcionan como cajas negras, requieren etiquetado manual costoso y tienen capacidad de generalización limitada en dominios no vistos.
Metodología	Se diseña un marco de sistema dual compuesto por un sistema de cognición y un sistema de decisión. El sistema se evalúa en los conjuntos de datos RAWFC, LIAR-RAW y un nuevo conjunto creado llamado WeiboEval, utilizando los modelos GPT-4o y GPT-4o-mini. La evaluación compara DelphiAgent contra 18 modelos base pertenecientes a 6 categorías diferentes.
Población / Ámbito	Sistemas automatizados de verificación de hechos (*fact-checking*) y detección de desinformación en plataformas de redes sociales en línea.
Intervención / Propuesta	DelphiAgent integra extracción de evidencia y toma de decisiones deliberativa mediante agentes con roles diferenciados. 1. **Módulo de extracción de evidencia (sistema de cognición):** utiliza dos LLMs, un extractor y un verificador, para recopilar y refinar evidencias a partir de reportes crudos sin censura, minimizando información irrelevante o errónea. 2. **Módulo de toma de decisiones Delphi (sistema de decisión):** emplea múltiples agentes LLM. Tres *Fact Checkers* con personalidades distintas (optimista, analítico/escéptico y crítico) evalúan la afirmación. Un *Synthesizer* agrega las decisiones y proporciona retroalimentación anónima iterativa, y finalmente un *Finalizer* toma la decisión de consenso.
Resultados Principales	DelphiAgent supera a los enfoques actuales basados en LLM y rinde a la par que los modelos supervisados de última generación sin necesidad de entrenamiento. En el conjunto RAWFC, mejoró el puntaje macF1 hasta en un 6.84 % respecto al mejor modelo base. Además, las justificaciones generadas a lo largo del flujo de trabajo mejoran significativamente la explicabilidad y confianza del sistema, mitigando las alucinaciones.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Topología iterativa, indirecta y basada en retroalimentación que emula el método Delphi. Los agentes evaluadores (*Fact Checkers*) no se comunican directamente entre sí para garantizar su independencia y anonimato; en su lugar, se comunican a través de un agente central (*Synthesizer*) que agrega sus posturas y les devuelve retroalimentación iterativa en múltiples rondas hasta alcanzar un consenso, tras lo cual un agente final (*Finalizer*) emite el dictamen.
Métricas reportadas	Se evalúa el desempeño mediante precisión promediada macro (Macro-averaged Precision, P), exhaustividad (Recall, R) y puntaje F1 (macF1).
Tipos de fallo colectivo considerados	El marco aborda directamente las alucinaciones, entendidas como generación de contenido no factual por parte del LLM. También mitiga el fallo de sesgo e información ruidosa, asociado a la "sabiduría de las masas" defectuosa en reportes sin censura, y el fallo en la toma de decisiones por pensamiento de grupo o sesgos de un solo paso, utilizando personalidades diversas (optimista, crítica, escéptica) y anonimato para asegurar posturas independientes.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El estudio presenta una excelente hibridación entre teorías cognitivas, como la teoría del sistema dual, y técnicas estructuradas de consenso humano, como el método Delphi, aplicadas a la inteligencia artificial. La asignación de personalidades divergentes para forzar perspectivas distintas es una forma efectiva de combatir las alucinaciones endémicas de los LLMs y enriquecer el debate interno del sistema.
Limitaciones / Sesgos	Los autores reportan que el sistema tiene un desempeño menor al esperado en conjuntos de datos con etiquetas de veracidad de grano fino, por ejemplo al diferenciar entre "Medio Verdad" y "Apenas Verdad", ya que esto complica el proceso de razonamiento. Además, realizar múltiples llamadas iterativas a modelos grandes como GPT-4o aumenta considerablemente los costos de inferencia.
Conclusión del Autor	DelphiAgent logra mejoras notables sobre los enfoques actuales de LLM y compite con modelos supervisados sin requerir entrenamiento previo, validando que el mecanismo de retroalimentación iterativa y síntesis inspirado en Delphi es altamente efectivo para mitigar alucinaciones y lograr una verificación de hechos explicable y confiable.
Impresión del Estudiante	⋆⋆⋆⋆⋆ **(Excelente).** Es un artículo fundamental para la revisión sistemática, ya que ejemplifica cómo una arquitectura de comunicación restrictiva e iterativa, inspirada en dinámicas sociales humanas como Delphi, puede superar las limitaciones técnicas puras de los modelos de lenguaje en tareas críticas como la verificación de la verdad.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: La clave estructural de este paper es que rompe con la topología de comunicación lineal típica de muchos frameworks de agentes. Al interponer un *Synthesizer* que oculta la identidad de los agentes entre sí y resume los hallazgos en cada ronda, previene que un agente asuma el liderazgo e imponga sus alucinaciones o errores a los demás.

Relación con la revisión sistemática: Este artículo aporta evidencia directa a la categoría de topologías de interacción enfocadas en el consenso. Sirve para contrastar sistemas de comunicación abierta, donde todos hablan con todos, frente a sistemas de comunicación mediada, como este mediante el *Synthesizer*, demostrando que introducir fricciones o reglas formales de comunicación mejora la robustez frente a errores y la objetividad final.