FICHA DE EXTRACCIÓN DE INFORMACIÓN
(REVISIÓN SISTEMÁTICA)

Guía Universitaria (UNAP) | Basado en Mian *et al.* (2005) & PRISMA

---

1. IDENTIFICACIÓN Y CLASIFICACIÓN DEL ESTUDIO

Referencia	ID Hoja	Año
Yang, Y., Ma, Y., Feng, H., Cheng, Y., & Han, Z. (2025). Minimizing Hallucinations and Communication Costs: Adversarial Debate and Voting Mechanisms in LLM-Based Multi-Agents. *Applied Sciences*, 15(7), 3676. DOI: 10.3390/app15073676	V-10	2025

Tipo de Estudio	Base de Datos	Indexación
Artículo de investigación original / propuesta metodológica.	MDPI — *Applied Sciences*	Revista científica indexada

2. EJECUCIÓN Y RESULTADOS OBJETIVOS (EVIDENCIA)

Campo	Información Extraída
Objetivo (Intención)	Proponer un marco de LLM multiagente que incorpore mecanismos de debate adversarial y votación para mitigar de forma conjunta las alucinaciones y reducir los costos de comunicación, empleando técnicas de compresión de entropía.
Problema / Brecha	Las alucinaciones limitan severamente el uso de LLMs en dominios críticos como medicina, ámbito militar y legal. Además, en los debates para resolverlas, el exceso de rondas de diálogo incrementa los costos computacionales y puede amplificar las alucinaciones introduciendo contenido no fáctico. Por su parte, los enfoques individuales sufren el problema de degeneración de pensamiento (DoT), siendo incapaces de autocorregirse solos.
Metodología	Se desarrolló un sistema evaluado iterativamente procesando información en lotes de 50 preguntas. Las pruebas utilizaron los *datasets* MMLU, GSM8K y HaluEval. Se emplearon múltiples modelos *open-source* divididos en grupos, por ejemplo el grupo del MIT (Orca, WizardLM y Vicuna) y un grupo doméstico. El marco se entrenó u optimizó resolviendo una función de penalización adaptativa basada en gradientes que equilibra tokens usados, tiempo de respuesta y tasa de alucinaciones.
Población / Ámbito	Sistemas multiagente basados en LLM aplicados a la resolución de consultas complejas, matemáticas y de conocimiento general, con aplicación potencial en escenarios sensibles al tiempo y a los recursos, como salud y operaciones militares.
Intervención / Propuesta	El estudio integra autocorrección individual, debate multiagente y optimización del costo comunicacional. 1. **Mecanismo de un solo LLM (autocorrección):** implementa consultas repetitivas internamente y un registro de errores (*error log*) para activar autorreflexión cuando se supera un umbral, obligando al modelo a modificar su propio *prompt*. 2. **Procesamiento multiagente:** diferentes LLMs entablan un debate adversarial coordinado por un agente sintetizador. Utilizan votación apoyada en cadena de pensamiento (CoT) y ponderación dinámica basada en el historial de errores de cada agente. 3. **Optimización del sistema:** aplica métricas de compresión de entropía y penalización por alta varianza durante el diálogo para forzar el consenso temprano y minimizar rondas redundantes.
Resultados Principales	El sistema mejoró significativamente la precisión general, observándose una tendencia al alza constante en la precisión compuesta durante 20 lotes de evaluación. La introducción de ponderación dinámica permitió dar mayor protagonismo al agente más fiable en cada ronda, reduciendo tasas de error. Adicionalmente, los modelos con razonamiento CoT y métricas de consistencia combinadas lograron un salto de rendimiento, hasta 0.60 frente al 0.40 inicial en los *datasets* MMLU domésticos.

3. VARIABLES ESPECÍFICAS DE ANÁLISIS

Pregunta / Variable	Respuesta Extraída
Topología de comunicación empleada	Topología estructurada y colaborativa mediada por un sintetizador. Los agentes LLM generan sus propuestas de manera inicial descentralizada e independiente. Posteriormente, un agente sintetizador recopila, verifica inconsistencias y relanza desafíos para debate grupal. La red utiliza un enfoque de influencia asimétrica, donde el impacto de cada nodo en la decisión está dictado por una ponderación dinámica ajustada constantemente por su exactitud histórica.
Métricas reportadas	La evaluación integral incluye precisión compuesta (*Composite accuracy*), tasa de reducción de alucinaciones (*Hallucination reduction rate*), métrica de consistencia ponderada (*Weighted consistency metric*), eficiencia de diálogo medida por el número total de tokens consumidos (T_{total}) y eficiencia de tiempo medida por el tiempo total de respuesta ($T_{response}$).
Tipos de fallo colectivo considerados	Se aborda la susceptibilidad del grupo a amplificar alucinaciones si el número de intercambios es innecesariamente excesivo, generando ruido por sobre la retroalimentación útil. También considera la degeneración del pensamiento, entendida como estancamiento obstinado en el error, y previene ciclos de diálogos improductivos provocados por incertidumbre, alta entropía y desacuerdos crónicos, cortándolos con funciones de penalidad y un mecanismo centralizado de votación.

4. ANÁLISIS CRÍTICO Y CONCLUSIONES (SUBJETIVO)

Campo	Valoración del Investigador
Valoración del Investigador	El enfoque metodológico es brillante en la forma en que entrelaza la calidad de la respuesta con el costo computacional. En lugar de permitir que los agentes debatan ilimitadamente, imponer una penalización matemática fundamentada en la varianza y entropía soluciona el desgaste propio de las redes multiagentes complejas de manera elegante y eficiente.
Limitaciones / Sesgos	Los autores reconocen que la experimentación se desarrolló en una única máquina, sin abordar variables críticas de un entorno distribuido real como latencia de red o problemas de sincronización en la comunicación. Asimismo, indican desafíos de escalabilidad, ya que la evaluación de algunos lotes tardó hasta 27 horas, poniendo en duda su aplicación práctica inmediata en redes con cientos de agentes.
Conclusión del Autor	La integración conjunta de mecanismos de autocorrección interna, validación y debate cruzado entre diversos modelos, y técnicas de compresión de entropía resulta efectiva no solo para detectar y disminuir las alucinaciones, sino también para optimizar el tiempo de respuesta y los recursos de comunicación del sistema.
Impresión del Estudiante	⋆⋆⋆⋆⋆ **(Excelente).** Es una pieza técnica importantísima para el marco de la revisión porque, a diferencia de otros papers, incorpora los costos derivados de las topologías de interacción abierta. Ponderar a los participantes según su fiabilidad histórica y cortar la conversación redundante es clave para la viabilidad de estos sistemas.

5. OBSERVACIONES GENERALES Y NOTAS

N Nota

Nota principal: La utilización del mecanismo de registro de errores o *Error Log* para modificar el *prompt* en rondas internas de un mismo agente es un paso previo excelente. Permite limpiar errores triviales de manera aislada antes de enviarlos a la red de pares para el debate, ahorrando tokens y procesamiento.

Relación con la revisión sistemática: El texto brinda fuerte evidencia matemática sobre cómo moderar y condicionar los canales de comunicación de la topología mediante fórmulas de ponderación dinámica y métrica de consistencia ponderada, superando a los modelos estáticos igualitarios donde un agente débil tendría la misma oportunidad de arruinar el debate que uno fuerte.